

# Upscaling de Tomografia Computadorizada Utilizando uma Rede Neural Convolutacional

Fernando Seiti Furusato

June 2019

**Abstract**—As techniques for computed tomography reconstruction get more sophisticated and demanding, with the data getting larger, it is becoming necessary to find ways to make the reconstruction computationally possible, while keeping the quality of the output. This work proposes the usage of upscaling, but not in the traditional means – e.g. bicubic or bilinear interpolation – but through the use of machine learning, where a model for upscaling is learned from a network – the SRCNN in this case – and can be applied on downsampled images.

## I. INTRODUÇÃO

Neste trabalho, propõe-se a implementação de uma rede neural convolutacional que efetua a super-resolução de uma imagem bidimensional. A aplicação final dessa metodologia será tornar factível a reconstrução tomográfica[3] de um imagem, que seria impraticável em condições normais, devido à alta resolução da imagem final. Neste trabalho, no entanto, serão utilizados volumes de imagens com dimensões limitadas, em comparação com as amostras coletadas originalmente, para fins de demonstração. Em tese, não há um limite bem definido para qual resolução física uma imagem pode ser super-resolvida. No entanto, para que se obtenha dados mais próximos do real, a resolução do *upsampling* é limitada por uma correlação denominada FSC – Fourier Shell Correlation[6]. Neste trabalho, é aplicada a super-resolução para o dobro da resolução da imagem de entrada.

Apesar de dados tomográficos serem tridimensionais, a princípio, a técnica será aplicada em cada imagem (2D) que compõe um volume (3D) – as fatias – pois muitas análises e técnicas de segmentação também são feitas sobre as fatias.

## II. MATERIAIS E MÉTODOS

*Este paper reproduzível pode ser encontrado em <https://github.com/ferseiti/reproducibility>*

### A. Dados experimentais

Os dados iniciais consistem de experimentos de tomografia computadorizada, realizados na linha

de luz IMX do Laboratório Nacional de Luz Síncrotron[LNLS] em que foram adquiridas projeções em variados ângulos. São 3 amostras de diferentes objetos:

- Ponta de caneta esferográfica;
- Palito de madeira;
- Espinho de planta;

Originalmente, as medidas de cada amostra resultaram em projeções de 2048 ângulos, com cada projeção tendo dimensões de 2048 pixels de altura, 2048 pixels de largura e 8 bits de profundidade. Estas projeções são os dados brutos que, em seu estado original, resultam em arquivos de aproximadamente 8 gigabytes ( $(2048 \times 2048 \times 2048 \times 2)/(1024^3) = 8GB$ ). Para processar esses dados, seriam necessários recursos de memória, processamento e armazenamento impraticáveis para a disciplina, principalmente para que a reprodutibilidade seja possível para os colegas. Portanto, para fins de experimento e de reprodutibilidade, foi feita uma subamostragem dos dados brutos. Todos foram reduzidos para 512 ângulos e 512 pixels de altura e largura, resultando em arquivos de aproximadamente 250MB.

1) *Dados brutos*: Abaixo pode ser verificada uma projeção de amostra. Esses dados serão disponibilizados apenas para fins informativos, pois os dados reconstruídos estarão todos disponíveis para *download*. A reconstrução desses dados requer um software especial para tal fim, portanto esse procedimento não será contemplado por este trabalho.

2) *Reconstrução*: Após adquiridas as projeções, é necessário realizar a reconstrução tomográfica, a fim de se obter as imagens tridimensionais. Com o método de reconstrução tomográfica utilizado, é gerado um arquivo por fatia do volume tridimensional. Nas dimensões apresentadas, cada arquivo tem tamanho aproximado de 260 kilobytes. Para eliminar a necessidade de manter muitos arquivos, posteriormente fez-se um processamento para que as fatias sejam mantidas em um único arquivo. Na figuras 1 e 2 verifica-se a visualização de uma projeção e o corte em diferentes planos da imagem reconstruída. Para evitar uma grade quantidade de arquivos, optou-se por criar




Figura 1: a) Projeção do ângulo 256 da amostra. b) Sinograma da linha 256 do dado bruto.

um único arquivo contendo todas as fatias. O formato utilizado foi o HDF5, que é de simples utilização e pode ser manipulado por bibliotecas python.

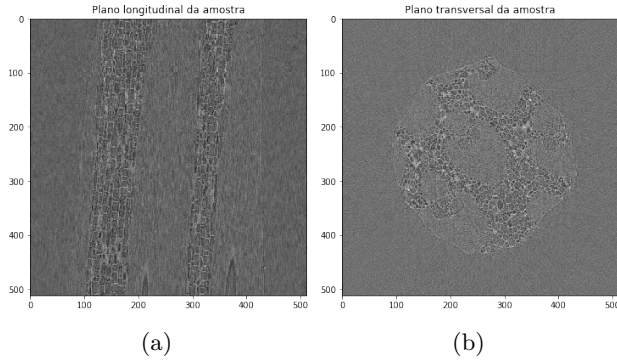


Figura 2: a) Plano longitudinal da amostra. b) Plano transversal da amostra.

3) *Preparação dos dados:* Para treino e validação da rede, primeiramente os dados sub-amostrados foram re-escalados para as dimensões das imagens *ground truth*, com interpolação bicúbica. A partir de então, foram geradas bases de dados contendo fragmentos de dimensões menores às das imagens de entrada e saída, para dado e anotação. Grande parte do código foi baseada em um código escrito anteriormente, mas para diferentes tipos de dados. Portanto, muitas adaptações tiveram de ser feitas. Foram 2 situações diferentes de extração de fragmentos: 1. Fragmentos de 32x32 pixels para dado de treinamento e 20x20 pixels para as *labels*. 2. Fragmentos de 64x64 pixels para dado de treinamento e 52x52 pixels para as *labels*. Esse redimensionamento para as *labels* teve de ser efetuada porque na primeira e terceira camadas convolucionais foi utilizado o modo *valid* que remove as bordas afetadas pelo efeito de borda da convolução. Como havia 3 amostras tridimensionais, 2 foram utilizadas para fazer o treino e validação, e uma foi

mantida para o teste.

## B. Metodologia

Esta seção descreve os métodos utilizados para a implementação da rede neural convolucional. A seção II-B1 contém uma descrição geral do conceito de *upscaling*, que é o objetivo final do algoritmo. A seção II-B2 apresenta uma breve introdução sobre redes neurais convolucionais e, finalmente, a seção II-B3 descreve brevemente a arquitetura da rede utilizada neste trabalho, SRCNN. O modelo finalmente escolhido, dentre as variações da SRCNN foi denominado, neste trabalho, 9-3-5, como poderá ser visto ao longo dos próximos tópicos deste trabalho.

1) *Upscaling:* As reconstruções apresentadas são as imagens em resultado ideal, com a resolução que se espera alcançar com o experimento proposto por este projeto. Para o experimento, foram feitas subamostragens dos dados brutos que, por sua vez, passaram pela reconstrução tomográfica, que então foram submetidas ao processo de *upscaling*. Ao final, os dados reconstruídos são volumes de 512 pixels cúbicos, para as imagens *ground truth* e 256 pixels cúbicos para as imagens reconstruídas a partir do dado subamostrado. Ou seja, reconstruções na escala maior, com 512x512x512 pixels serviram como *ground truth* para a rede convolucional utilizada.

2) *Redes Neurais Convolucionais:* Redes neurais convolucionais (CNN na sigla em inglês), assim como outras redes neurais artificiais, são baseadas em observações na natureza. Neste caso, especificamente, na arquitetura do córtex visual[2] de seres capazes de enxergar. Experimentos realizados com algumas espécies de animais concluíram que os neurônios responsáveis pelo processamento visual apenas reagem a estímulos em regiões limitadas do campo visual. Neste sentido, assim como a percepção visual observada nesses experimentos, em uma rede neural convolucional, os neurônios de uma camada não estão conectados a todos os neurônios da camada anterior, mas em uma região de interesse, limitada pela arquitetura da rede.

3) *SRCNN:* O objeto de estudo deste trabalho é uma rede convolucional específica, criada para realizar *upscaling* de imagens. Esta rede, chamada *Super-resolution Convolutional Neural Network*, SRCNN, por Dong[1] foi criada com o intuito de melhorar a resolução de imagens comuns, não direcionada exatamente para imagens tomográficas, o que pode fazer com que a rede necessite de ajustes para que funcione como o esperado para os dados deste trabalho.

Esta é uma rede convolucional relativamente simples. Ela contém apenas 3 camadas convolucionais, com ativação *rectified linear unit*, ReLU. A otimização utilizada originalmente pelo autor foi a descida de gradiente estocástica, mas como poderá ser observado, a otimização Adam[4] se mostrou mais efetiva para esta aplicação, através dos experimentos.




Figura 3: Arquitetura da SRCNN: 3 camadas convolucionais.

Como ilustrado na Figura 3, a rede foi desenhada de forma que cada uma das 3 camadas tivesse uma função bem definida:

- **Extração de retalhos e representação:** operação que extrai retalhos, como vetores de características da imagem, sendo que os vetores podem ter áreas de sobreposição entre eles.
- **Mapeamento não-linear:** mapeamento entre os vetores de características de entrada e saída.
- **Reconstrução:** geração da saída da rede, que deverá ser a imagem mais próxima à do *ground truth*.

Para a rede convolucional, como também demonstrado por Dong *et al*[1], variações nas dimensões do filtro da segunda camada também poderia ter influência no resultado, que também foram testadas para que fosse encontrado o melhor modelo. Foram feitas, basicamente, as 3 variações de tamanho de filtro em cada camada, mencionadas pelo autor:

- **9-1-5:** filtros 9x9 com 128 mapas de características, 1x1 com 64 mapas de características e 5x5;
- **9-3-5:** filtros 9x9 com 128 mapas de características, 3x3 com 64 mapas de características e 5x5;
- **9-5-5:** filtros 9x9 com 128 mapas de características, 5x5 com 64 mapas de características, e 5x5;

A métrica utilizada para visualização do resultado, a princípio, foi o erro quadrático médio, mas pôde-se verificar que esta pode não ser a melhor alternativa para o tipo de dado utilizado e gerado.

Seguindo o exemplo de Dong *et al*, também foi feita a medida da relação sinal-ruído de pico, PSNR, mas o resultado não se mostrou muito representativo.

Uma métrica mais apropriada, utilizada posteriormente, e que pode refletir bem a semelhança entre a saída e o *ground truth*, foi o índice de similaridade estrutural (SSIM). Essa métrica reflete no índice de similaridade entre as imagens, variando de 0 a 1, em que 0 significa nada similar e 1 totalmente similar (idêntico).

Além dos cenários descritos anteriormente, também foram feitos experimentos com variações de arquitetura. Algumas delas foram:

- **Variação nas dimensões das camadas:** essa variação resultou em um modelo não satisfatório. Visualmente, as predições não apresentavam nenhuma similaridade com o *ground truth*. Após 100 épocas, o modelo convergiu sem predições significativas.
- **Convolução no modo “same”** para todas as camadas: para tanto, também foi necessário gerar os dados de *ground truth* com as dimensões corretas (mesmas dimensões de entrada). Essa variação se apresentou levemente mais lenta, mas também resultou em predições não satisfatórias em comparação com as outras arquiteturas. Após 100 épocas, o modelo convergiu.

### III. RESULTADOS

Após os experimentos, o treinamento das redes e a escolha do melhor modelo, foi possível, então, verificar os resultados na base de dados de teste.

Os gráficos desta seção ilustram os resultados de treinamento. A variação que apresentou o melhor resultado foi a denominada 9-3-5, como poderá ser verificado a seguir.

#### A. Rede 9-1-5

Esta rede apresentou um comportamento não esperado, pois, após 50 épocas, o SSIM passou a decair rapidamente, chegando a 0.65 após 300 épocas.




Figura: SSIM x Épocas com a rede 9-1-5.

### B. Rede 9-5-5

Após 100 épocas, esta rede apresentou resultados visualmente melhores e SSIM de 0.95, mas foi mais lenta (aproximadamente 8 horas para 600 épocas) e se mostrou inferior à rede 9-3-5, como discutido a seguir. Os resultados estão ilustrados abaixo.

### C. Rede 9-3-5

Esta rede, após 80 épocas, apresentou SSIM acima de 0.96. Os resultados desta rede, comparados com as outras, foram mais satisfatórios, mas não se aproximam significativamente do *ground truth*.




Figura 4: SSIM x Épocas com a rede 9-3-5.

Este foi o melhor modelo nas bases de treino e, por este motivo, foi também aplicado na base de teste, como pode ser verificado a seguir. Abaixo é possível visualizar os resultados da rede 9-3-5 na amostra utilizada para teste. A imagem abaixo representa a fatia 256 do volume:




Figura 5: Fatia 256 dos dados de teste.

## IV. CONCLUSÕES E TRABALHOS FUTUROS

Com os resultados obtidos neste, pode-se verificar que é possível treinar uma rede para obter bons resultados de super resolução em imagens tomográficas. Foi possível concluir que é possível obter resultados satisfatórios, mas que, para tanto, deve-se considerar pontos importantes como:

- Ajustes na rede: ajustes como alteração nas dimensões de filtros e mapas de características e inserção de mais camadas convolucionais ou de pooling poderiam contribuir positivamente para a arquitetura desta rede, nesta aplicação.
- Outras arquiteturas: testar outras arquiteturas de redes de deep learning podem ser benéficas para esse tipo de trabalho, pois é possível que outras propostas sejam mais adequadas para o tipo de dado apresentado.
- Maior variedade de dados: os dados utilizados apresentam pouca variação. Isso afeta o modelo negativamente, que pode apresentar overfitting devido aos dados muito uniformes entre si.
- Função de custo: a função de custo utilizada não se mostrou eficaz, já que, para o tipo de dado utilizado, existem métricas mais apropriadas.

## REFERÊNCIAS

- [1] Dong, C., Loy, C. C., He, K., and Tang, X. (2016). Image super-resolution using deep convolutional networks. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 38(2):295–307.
- [2] HUBEL, D. H. (1959). Single unit activity in striate cortex of unrestrained cats. *The Journal of physiology*, 147,2.
- [3] Kak, A., Slaney, M., in Medicine, I. E., and Society, B. (1988). *Principles of Computerized Tomographic Imaging*. IEEE Press.
- [4] Kingma, D. P. and Ba, J. (2014). Adam: A Method for Stochastic Optimization. *arXiv e-prints*, page arXiv:1412.6980.
- [LNLS] LNLS. Sirius, a nova fonte de luz síncrotron brasileira.
- [6] van Heel, M. and Schatz, M. (2005). Fourier shell correlation threshold criteria. *Journal of Structural Biology*, 151(3):250 – 262.